→ Домашнее задание 3.

Предсказание пользовательской оценки отеля по тексту отзыва.

В данном домашнем задании вам будет обучиться на данных с кэггла и заслать в соревнование предикт. Чтобы контест отображался, откройте и примите условия участия в контесте через ссылку-приглашение в телеграм-канале. По той же ссылке можете скачать данные.

Мы собрали для вас отзывы по 1500 отелям из совершенно разных уголков мира. Что это за отели - секрет. Вам дан текст отзыва и пользовательская оценка отеля. Ваша задача - научиться предсказывать оценку отеля по отзыву.

Главная метрика - Mean Absolute Error (MAE). Во всех частях домашней работы вам нужно получить значение MAE не превышающее 0.92 на публичном лидерборде. В противном случае мы будем вынуждены не засчитать задание :(

▼ Про данные:

Каждое ревью состоит из двух текстов: positive и negative - плюсы и минусы отеля. В столбце score находится оценка пользователя - вещественное число 0 до 10. Вам нужно извлечь признаки из этих текстов и предсказать по ним оценку.

Для локального тестирования используйте предоставленное разбиение на трейн и тест.

Good luck & have fun! 💪

Использовать любые данные для обучения кроме предоставленных

 ▼ организаторами строго запрещено. В последней части можно использовать предобученные модели из библиотеки transformers.

```
PATH_TO_TRAIN_DATA = '/content/train.csv'
PATH_TO_TEST_DATA = './test.csv'

import pickle
import pandas as pd
import numpy as np
```

```
from tqdm import tqdm
from sklearn.model selection import train test split
```

! pip install gensim

```
Requirement already satisfied: gensim in /usr/local/lib/python3.7/dist-packages (3.6 Requirement already satisfied: six>=1.5.0 in /usr/local/lib/python3.7/dist-packages Requirement already satisfied: numpy>=1.11.3 in /usr/local/lib/python3.7/dist-packag Requirement already satisfied: scipy>=0.18.1 in /usr/local/lib/python3.7/dist-packag Requirement already satisfied: smart-open>=1.2.1 in /usr/local/lib/python3.7/dist-pa
```

! pip install catboost

Collecting catboost

Downloading catboost-1.0.4-cp37-none-manylinux1_x86_64.whl (76.1 MB)

| 76.1 MB 1.3 MB/s

Requirement already satisfied: scipy in /usr/local/lib/python3.7/dist-packages (from Requirement already satisfied: six in /usr/local/lib/python3.7/dist-packages (from c Requirement already satisfied: pandas>=0.24.0 in /usr/local/lib/python3.7/dist-packages (from Requirement already satisfied: graphviz in /usr/local/lib/python3.7/dist-packages (from Requirement already satisfied: plotly in /usr/local/lib/python3.7/dist-packages (from Requirement already satisfied: matplotlib in /usr/local/lib/python3.7/dist-packages Requirement already satisfied: numpy>=1.16.0 in /usr/local/lib/python3.7/dist-package Requirement already satisfied: pytz>=2017.3 in /usr/local/lib/python3.7/dist-package Requirement already satisfied: python-dateutil>=2.7.3 in /usr/local/lib/python3.7/dist-package Requirement already satisfied: cycler>=0.10 in /usr/local/lib/python3.7/dist-package Requirement already satisfied: kiwisolver>=1.0.1 in /usr/local/lib/python3.7/dist-package Requirement already satisfied: pyparsing!=2.0.4,!=2.1.2,!=2.1.6,>=2.0.1 in /usr/loca Requirement already satisfied: tenacity>=6.2.0 in /usr/local/lib/python3.7/dist-package Installing collected packages: catboost Successfully installed catboost-1.0.4

#! wget https://raw.githubusercontent.com/SaidDandamaev/Projects of Said D/main/Work files

--2022-03-17 08:30:10-- https://raw.githubusercontent.com/SaidDandamaev/Projects_of Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.108.133, Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.108.133|
HTTP request sent, awaiting response... 404 Not Found
2022-03-17 08:30:10 ERROR 404: Not Found.

→

#! wget https://raw.githubusercontent.com/SaidDandamaev/Projects_of_Said_D/main/Work_files
#! wget https://raw.githubusercontent.com/hse-ds/iad-deep-learning/master/2021/seminars/se

--2022-03-17 08:30:10-- https://raw.githubusercontent.com/SaidDandamaev/Projects_of Resolving raw.githubusercontent.com (raw.githubusercontent.com)... 185.199.109.133, Connecting to raw.githubusercontent.com (raw.githubusercontent.com)|185.199.109.133|
HTTP request sent, awaiting response... 404 Not Found
2022-03-17 08:30:10 ERROR 404: Not Found.

```
df = pd.read_csv(PATH_TO_TRAIN_DATA)[:20000]
df.head()
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 4 columns):
    Column Non-Null Count Dtype
             -----
___
0 review_id 20000 non-null object
             20000 non-null object
1
    negative
2
    positive 20000 non-null object
              20000 non-null float64
3
    score
dtypes: float64(1), object(3)
memory usage: 625.1+ KB
```

Предобработка текста может сказываться на качестве вашей модели.

Сделаем небольшой препроцессинг текстов: удалим знаки препинания, приведем все слова к нижнему регистру. Однако можно не ограничиваться этим набором преобразований. Подумайте, что еще можно сделать с текстами, чтобы помочь будущим моделям? Добавьте преобразования, которые могли бы помочь по вашему мнению.

Также мы добавили разбиение текстов на токены. Теперь каждая строка-ревью стала массивом токенов. (у меня для 1 задания это будет не массив а все та же строка)

```
import string
import nltk
nltk.download('punkt')
from nltk.tokenize import word_tokenize
nltk.download('stopwords')
from nltk.corpus import stopwords
     [nltk_data] Downloading package punkt to /root/nltk_data...
     [nltk data] Unzipping tokenizers/punkt.zip.
     [nltk_data] Downloading package stopwords to /root/nltk_data...
     [nltk_data] Unzipping corpora/stopwords.zip.
punctuation = string.punctuation
noise = stopwords.words('english') + list(punctuation) + list('1234567890')
#noise = list(punctuation) + list('1234567890')
def process_text(text):
    lst = [word for word in word_tokenize(text.lower()) if (word not in noise)]
    return ' '.join(lst)
df['negative'] = df['negative'].apply(process_text) # ячейка выполняется 30 сек
df['positive'] = df['positive'].apply(process_text)
df.head()
```

```
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 4 columns):
    Column
              Non-Null Count Dtype
    -----
              _____
0
    review_id 20000 non-null object
              20000 non-null object
1
    negative
2
    positive
              20000 non-null object
3
    score
              20000 non-null float64
dtypes: float64(1), object(3)
memory usage: 625.1+ KB
```

df_train, df_test = train_test_split(df, test_size=0.2, random_state=1412) # <- для локаль

▼ Часть 1. 1 балл

Обучите логистическую регрессию на TF-IDF векторах текстов.

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression, LinearRegression, SGDRegressor
from sklearn.metrics import mean_absolute_error

count_tf_idf_neg = TfidfVectorizer()#ngram_range=(2,2))
count_tf_idf_pos = TfidfVectorizer()#ngram_range=(2,2))

tf_idf_pos_train = count_tf_idf_pos.fit_transform(df_train['positive'])
tf_idf_neg_train = count_tf_idf_neg.fit_transform(df_train['negative'])

tf_idf_pos_test = count_tf_idf_pos.transform(df_test['positive'])
tf_idf_neg_test = count_tf_idf_neg.transform(df_test['negative'])
```

X_train_pos = pd.DataFrame(tf_idf_pos_train.toarray(),columns=count_tf_idf_pos.get_feature
X_train_neg = pd.DataFrame(tf_idf_neg_train.toarray(),columns=count_tf_idf_neg.get_feature
X_train = pd.concat([X_train_neg.reset_index(drop=True), X_train_pos.reset_index(drop=True)
del X_train_pos, X_train_neg

/usr/local/lib/python3.7/dist-packages/sklearn/utils/deprecation.py:87: FutureWarnin warnings.warn(msg, category=FutureWarning)

```
◆
```

X_test_pos = pd.DataFrame(tf_idf_pos_test.toarray(),columns=count_tf_idf_pos.get_feature_r
X_test_neg = pd.DataFrame(tf_idf_neg_test.toarray(),columns=count_tf_idf_neg.get_feature_r
X_test = pd.concat([X_test_neg.reset_index(drop=True), X_test_pos.reset_index(drop=True)],
del X_test_pos, X_test_neg

/usr/local/lib/python3.7/dist-packages/sklearn/utils/deprecation.py:87: FutureWarnin
warnings.warn(msg, category=FutureWarning)

```
→
```

```
model_1_log = SGDRegressor(max_iter=1000, random_state=1221) # r_s 1221 дает 0.9 на мае (є model_1_log.fit(X_train, df_train['score'])
mae_log = mean_absolute_error(df_test['score'], model_1_log.predict(X_test))
print(f'On Linear regression with TF-IDF MAE = {mae_log:.4f}')

On Linear regression with TF-IDF MAE = 0.9062
CPU times: user 1min 29s, sys: 874 ms, total: 1min 30s
Wall time: 1min 44s
```

Качество меньше 0.9 на всех выборках - great

Предскажите этой моделью тестовые данные из <u>соревнования</u> и сделайте сабмит. Какой у вас получился скор? Прикрепите скриншот из кэггла.

Score was about 0.89



▼ Часть 2. 2 балла

Обучите линейную регрессию на усредненных **Word2Vec** векторах.

```
noise = list(punctuation) + list('1234567890')

def process_text(text):
    lst = [word for word in word_tokenize(text.lower()) if (word not in noise)]
    return ' '.join(lst)

df = pd.read_csv(PATH_TO_TRAIN_DATA)[:50000] # заного читаю, чтоб взять 60льшую выборку

df['negative'] = df['negative'].apply(process_text) # ячейка выполняется 30 сек

df['positive'] = df['positive'].apply(process_text)

df['positive'] = df['positive'].str.split()

df['negative'] = df['negative'].str.split()

df.head(3)
```

```
df3 = df.copy()
# взято с сайта https://medium.com/analytics-vidhya/word2vector-using-gensim-e055d35f1cb4
from gensim.models.word2vec import Word2Vec as w2v
import multiprocessing
emb_size = 200
arr_emb_size = []
arr_score_no_idf = []
arr_score_yes_idf = []
cpu_c = multiprocessing.cpu_count()
word_2_vec_model_pos = w2v(df['positive'], min_count=4, window=4, size=emb_size, workers=c
word_2_vec_model_neg = w2v(df['negative'], min_count=4, window=4, size=emb_size, workers=c
def make_arrays_for_text_pos(value):
   out_array = np.zeros(emb_size)
   count = 0
   for el in value:
        try:
            out_array += word_2_vec_model_pos.wv[el]
            count += 1
        except:
            continue
    return out_array / count
# усредняем. Идею именно этой ячейки подсказал друг, но реализовал сам
def make_arrays_for_text_neg(value):
   out_array = np.zeros(emb_size)
    count = 0
   for el in value:
        try:
            out array += word 2 vec model neg.wv[el]
            count += 1
        except:
            continue
    return out_array / count
df2 = df.copy()
df['positive_vector'] = df['positive'].apply(make_arrays_for_text_pos)
df['negative_vector'] = df['negative'].apply(make_arrays_for_text_neg)
X_features = pd.DataFrame(np.hstack((np.array(list(df.iloc[:, 4].values))),
                                     np.array(list(df.iloc[:, 5].values)))))
```

```
X_features['score'] = df['score']
X_features = X_features.fillna(0)
train, test = train_test_split(X_features, test_size=0.2, random_state = 1412)

model_2 = LinearRegression()
model_2.fit(train.drop('score', axis=1), train['score'])
no_idf_score = mean_absolute_error(model_2.predict(test.drop('score', axis=1)), test['score'])
print(f'MAE with Word2Vec medium = {no_idf_score:.4f}')

MAE with Word2Vec medium = 0.9465
```

Усредняя w2v вектора, мы предполагаем, что каждое слово имеет равноценный вклад в смысл предложения, однако это может быть не совсем так. Теперь попробуйте воспользоваться другой концепцией и перевзвесить слова при получении итогового эмбеддинга текста. В качестве весов используйте IDF (Inverse document frequency)

```
def calc_idf(needed_tf_idf):
    return dict(zip(needed_tf_idf.get_feature_names(), needed_tf_idf.idf_))

count_tf_idf_neg = TfidfVectorizer()
count_tf_idf_pos = TfidfVectorizer()

tf_idf_pos_train = count_tf_idf_pos.fit_transform(df_train['positive'])

tf_idf_neg_train = count_tf_idf_neg.fit_transform(df_train['negative'])

pos_dict_idf = calc_idf(count_tf_idf_pos)
neg_dict_idf = calc_idf(count_tf_idf_neg)

/usr/local/lib/python3.7/dist-packages/sklearn/utils/deprecation.py:87: FutureWarnin warnings.warn(msg, category=FutureWarning)
/usr/local/lib/python3.7/dist-packages/sklearn/utils/deprecation.py:87: FutureWarnin warnings.warn(msg, category=FutureWarning)
```

def make annous for tout nos idf(value):

```
def make_arrays_for_text_pos_idf(value):
    out_array = np.zeros(emb_size)
    for el in value:
        try:
            out_array += word_2_vec_model_pos.wv[el] * pos_dict_idf[el]
        except:
            continue
    return out_array
# усредняем. Идею именно этой ячейки подсказал друг, но реализовал сам

def make_arrays_for_text_neg_idf(value):
    out_array = np.zeros(emb_size)
    for el in value:
        try:
```

```
out_array += word_2_vec_model_neg.wv[el] * neg_dict_idf[el]
except:
    continue
return out_array

df2['positive_vector'] = df2['positive'].apply(make_arrays_for_text_pos_idf)
df2['negative_vector'] = df2['negative'].apply(make_arrays_for_text_neg_idf)

df2.head()
```

Чтобы изменить содержимое ячейки, дважды нажмите на нее (или выберите "Ввод")

Проведите эксперименты с размерностью эмбеддинга. Для каждого из двух методов постройте график зависимости качества модели от размерности эмбеддинга.

▼ Сделайте выводы:

Поиском по сетке найдем лучшую модель

```
import time
start_time = time.time()
arr emb size = []
arr_score_no_idf = []
arr_score_yes_idf = []
for emb_size in tqdm(range(300, 701, 100)):
   arr_emb_size.append(emb_size)
   cpu_c = multiprocessing.cpu_count()
   word_2_vec_model_pos = w2v(df['positive'], min_count=4, window=4, size=emb_size, worke
                               iter=15)
   word_2_vec_model_neg = w2v(df['negative'], min_count=4, window=4, size=emb_size, worke
                               iter=15)
   df = df3.copy()
   df2 = df.copy()
   df['positive_vector'] = df['positive'].apply(make_arrays_for_text_pos)
   df['negative_vector'] = df['negative'].apply(make_arrays_for_text_neg)
   X_features = pd.DataFrame(np.hstack((np.array(list(df.iloc[:, 4].values))),
                                     np.array(list(df.iloc[:, 5].values)))))
   X_features['score'] = df['score']
   X_features = X_features.fillna(0)
   train, test = train_test_split(X_features, test_size=0.2, random_state = 1412)
   model_2 = LinearRegression()
   model 2.fit(train.drop('score', axis=1), train['score'])
    no_idf_score = mean_absolute_error(model_2.predict(test.drop('score', axis=1)), test['
    arr_score_no_idf.append(no_idf_score)
    df2['positive_vector'] = df2['positive'].apply(make_arrays_for_text_pos_idf)
    df2['negative_vector'] = df2['negative'].apply(make_arrays_for_text_neg_idf)
   X_features = pd.DataFrame(np.hstack((np.array(list(df2.iloc[:, 4].values)),
                                     np.array(list(df2.iloc[:, 5].values)))))
   X_features['score'] = df2['score']
   X_features = X_features.fillna(0)
    train2, test2 = train_test_split(X_features, test_size=0.3, random_state = 1412)
```

```
model 3 = LinearRegression()
    model 3.fit(train2.drop('score', axis=1), train2['score'])
    idf_score = mean_absolute_error(test2['score'], model_3.predict(test2.drop('score', a)
    arr_score_yes_idf.append(idf_score)
print("--- %s seconds ---" % (round(time.time() - start_time, 4)))
     100%| 5/5 [07:40<00:00, 92.20s/it]--- 461.0058 seconds ---
import matplotlib.pyplot as plt
fig = plt.figure(figsize=(9,9))
plt.plot(arr_emb_size, arr_score_no_idf, label = "No_idf_word2vec")
plt.plot(arr_emb_size, arr_score_yes_idf, label = "Idf_word2vec")
fig.suptitle('MAE and Embedding Size', fontsize=20)
plt.xlabel('Emb_size', fontsize=18)
plt.ylabel('MAE', fontsize=18)
plt.legend()
plt.grid()
plt.show()
```

лучший эмбеддинг при emb_size = 500

```
import time
start time = time.time()
best_min_count = 0
best_window = 0
best res = 11
arr_score_no_idf = []
best min count idf = 0
best_window_idf = 0
best res idf = 11
best_mod_no_idf = None
arr_score_idf = []
best_model_idf = None
best_w_2_v_pos = None
best_w_2_v_neg = None
#arr_score_yes_idf = []
for windows in tqdm([7, 8]):
    for min_count in tqdm([ 5, 6]):
        emb_size = 500
        cpu_c = multiprocessing.cpu_count()
        word_2_vec_model_pos = w2v(df['positive'], min_count=min_count,
                                   window=windows, size=emb_size, workers=cpu_c, seed=122,
        word_2_vec_model_neg = w2v(df['negative'], min_count=min_count,
                                   window=windows, size=emb_size, workers=cpu_c, seed=1223
        df = df3.copv()
        df2 = df.copy()
        df['positive_vector'] = df['positive'].apply(make_arrays_for_text_pos)
        df['negative vector'] = df['negative'].apply(make arrays for text neg)
        X_features = pd.DataFrame(np.hstack((np.array(list(df.iloc[:, 4].values)),
                                         np.array(list(df.iloc[:, 5].values)))))
        X features['score'] = df['score']
        X_features = X_features.fillna(0)
        train, test = train_test_split(X_features, test_size=0.2, random_state = 1412)
        model 2 = LinearRegression()
        model_2.fit(train.drop('score', axis=1), train['score'])
        no_idf_score = mean_absolute_error(model_2.predict(test.drop('score', axis=1)), tε
        arr score no idf.append(no idf score)
        if no idf score < best res:
            best res = no idf score
```

```
best_window = windows
            best min count = min count
            best_mod_no_idf = model_2
        df2['positive_vector'] = df2['positive'].apply(make_arrays_for_text_pos_idf)
        df2['negative_vector'] = df2['negative'].apply(make_arrays_for_text_neg_idf)
        X_features = pd.DataFrame(np.hstack((np.array(list(df2.iloc[:, 4].values))),
                                         np.array(list(df2.iloc[:, 5].values)))))
        X_features['score'] = df2['score']
        X_features = X_features.fillna(0)
        print(X_features.shape)
        train2, test2 = train_test_split(X_features, test_size=0.2, random_state = 1412)
        model_3 = LinearRegression()
        model_3.fit(train2.drop('score', axis=1), train2['score'])
        idf_score = mean_absolute_error(test2['score'], model_3.predict(test2.drop('score')
        if idf_score < best_res_idf:</pre>
            best_res_idf = idf_score
            best_window_idf = windows
            best_min_count_idf = min_count
            best_model_idf = model_3
            best_w_2_v_pos = word_2_vec_model_pos
            best_w_2_v_neg = word_2_vec_model_neg
print("--- %s seconds ---" % (round(time.time() - start_time, 4)))
       0%
                    | 0/2 [00:00<?, ?it/s]
       0%|
                    | 0/2 [00:00<?, ?it/s](50000, 1001)
                   | 1/2 [01:39<01:39, 99.67s/it](50000, 1001)
      50%
               | 2/2 [03:11<00:00, 95.86s/it]
     100%
                    | 1/2 [03:11<03:11, 191.73s/it]
      50%
       0%|
                    0/2 [00:00<?, ?it/s](50000, 1001)
      50%
                    1/2 [01:36<01:36, 96.08s/it](50000, 1001)
                    | 2/2 [03:11<00:00, 95.53s/it]
                   | 2/2 [06:22<00:00, 191.40s/it]--- 382.8225 seconds ---
print('Without IDF best res = {}, parameters = {} and {}'.format(best res, best window, bε
print('With IDF best res = {}, parameters = {} and {}'.format(best_res_idf, best_window_ic
    Without IDF best res = 0.9268714831873073, parameters = 8 and 5
    With IDF best res = 0.9119240812649141, parameters = 7 and 5
```

Теперь попробуйте обучить логистическую регрессию на любых других эмбеддингах размерности 300 и сравните качество с Word2Vec.

▼ Выводы:

Я выбил нужное качество - **менее 0.92**! В итоге надо было не убирать Стоп-слова, и тогда ворд2век контекст лучше понимает

```
def make_arrays_for_text_pos_idf_fast_text(value):
   out_array = np.zeros(emb_size)
   count = 0
   for el in value:
        try:
            out_array += fast_text_model_pos.wv[el]
            count += 1
        except:
            continue
    return out_array / count
# усредняем. Идею именно этой ячейки подсказал друг, но реализовал сам
def make_arrays_for_text_neg_idf_fast_text(value):
    out_array = np.zeros(emb_size)
   count = 0
    for el in value:
        try:
            out_array += fast_text_model_neg.wv[el]
            count += 1
        except:
            continue
    return out_array / count
def make_arrays_for_text_pos_idf(value):
   out_array = np.zeros(emb_size)
    for el in value:
            out_array += best_w_2_v_pos.wv[el] * pos_dict_idf[el]
        except:
            continue
    return out array
# усредняем. Идею именно этой ячейки подсказал друг, но реализовал сам
def make_arrays_for_text_neg_idf(value):
   out_array = np.zeros(emb_size)
    for el in value:
        try:
            out_array += best_w_2_v_neg.wv[el] * neg_dict_idf[el]
        except:
            continue
    return out_array
from gensim.models.fasttext import FastText as FT
fast_text_model_pos = FT(df['positive'], size=300, workers=cpu_c, sg=1, seed=3, iter=20)
fast text model neg = FT(df['negative'], size=300, workers=cpu c, sg=1, seed=3, iter=20)
print('Going well')
```

```
df = df3.copy()
df2 = df.copy()
df2['positive_vector'] = df2['positive'].apply(make_arrays_for_text_pos_idf_fast_text)
df2['negative_vector'] = df2['negative'].apply(make_arrays_for_text_neg_idf_fast_text)
X_features = pd.DataFrame(np.hstack((np.array(list(df2.iloc[:, 4].values)),
                                 np.array(list(df2.iloc[:, 5].values)))))
X_features['score'] = df2['score']
X_features = X_features.fillna(0)
train2, test2 = train_test_split(X_features, test_size=0.3, random_state = 1412)
model_4 = LinearRegression()
model_4.fit(train2.drop('score', axis=1), train2['score'])
mean_absolute_error(test2['score'], model_4.predict(test2.drop('score', axis=1)))
     Going well
     1.3115023481904762
# data_test = pd.read_csv(PATH_TO_TEST_DATA)
# data_test['negative'] = data_test['negative'].apply(process_text) # ячейка выполняется 3
# data_test['positive'] = data_test['positive'].apply(process_text)
# data_test['positive'] = data_test['positive'].str.split()
# data_test['negative'] = data_test['negative'].str.split()
# data_test['positive_vector'] = data_test['positive'].apply(make_arrays_for_text_pos_idf)
# data_test['negative_vector'] = data_test['negative'].apply(make_arrays_for_text_neg_idf)
# X_featurest = pd.DataFrame(np.hstack((np.array(list(data_test.loc[:, 'positive_vector'].
#
                                           np.array(list(data_test.loc[:, 'negative_vector
# X_featurest = X_featurest.fillna(0)
# pred = best_model_idf.predict(X_featurest)
# pd.DataFrame({'review_id': data_test['review_id'], 'score': pred}).to_csv('My_sub2.3.csv
```

Предскажите вашей лучшей моделью из этого задания тестовые данные из соревнования и сделайте сабмит. Какой у вас получился скор? Прикрепите скриншот из кэггла.

<u>image.png</u>

Я сделал модель, которая у меня в разбиение набирает нужные 0.91, а в кэгле это очень близко к этому. Ворд 2 век показал неплохо себя, хоть и хуже tf-idf, fasttext у меня плоховато сработал

▼ Часть 3. 4 балла

Теперь давайте воспользуемся более продвинутыми методами обработки текстовых данных, которые мы проходили в нашем курсе. Обучите RNN/Transformer для предсказания пользовательской оценки. Получите ошибку меньше, чем во всех вышеперечисленных методах.

Если будете обучать RNN, попробуйте ограничить максимальную длину предложения. Некоторые отзывы могут быть слишком длинные относительно остальных.

Чтобы пользоваться DataLoader, все его элементы должны быть одинаковой размерности. Для этого вы можете добавить нулевой паддинг ко всем предложениям (см пример pad_sequence)

```
import torch
from torch import nn
from torch.nn import functional as F
import random

df_rnn = pd.read_csv(PATH_TO_TRAIN_DATA)[:50000]
df_rnn.head(3)
```

```
noise = stopwords.words('english') + list(punctuation) + list('1234567890')
#noise = list(punctuation) + list('1234567890')

def process_text(text):
    lst = [word for word in word_tokenize(text.lower()) if (word not in noise)]
    return lst

df_rnn['positive'] = df_rnn['positive'].apply(process_text)

df_rnn['negative'] = df_rnn['negative'].apply(process_text)

df_rnn.head()
```

WORDS = set()

```
for sent in list(df_rnn['positive']):
    for w in sent:
        WORDS.add(w)
for sent in list(df_rnn['negative']):
    for w in sent:
        WORDS.add(w)
int2word = dict(enumerate(tuple(WORDS)))
word2int = {w: ii for ii, w in int2word.items()}
len(WORDS)
     24544
MAX_LEN = max(max(df_rnn['positive'].apply(len)), max(df_rnn['negative'].apply(len)))
device = 'cuda:0'
MAX_LEN
     210
from torch.nn.utils.rnn import pad_sequence
df_train, df_test = train_test_split(df_rnn, test_size=0.2, random_state=1412) # <- для лс
train_pos_pad = pad_sequence([torch.as_tensor([word2int[w] for w in seq][:int(MAX_LEN - 0.
                           batch_first=True)
train_neg_pad = pad_sequence([torch.as_tensor([word2int[w] for w in seq][:int(MAX_LEN - 0.
                           batch first=True)
train_pad = torch.cat([train_pos_pad,train_neg_pad ], 1)
class ReviewsDataset(torch.utils.data.Dataset):
    def __init__(self, X, y):
        try:
```

```
self.X = X.numpy()
            self.y = y.to numpy()
        except:
            self.X = X.numpy()
            self.y = y
   def __len__(self):
        return len(self.y)
   def __getitem__(self, idx):
        return self.X[idx], self.y[idx]
def set random seed(seed):
   torch.backends.cudnn.deterministic = True
    torch.manual seed(seed)
   torch.cuda.manual_seed(seed)
   np.random.seed(seed)
    random.seed(seed)
set_random_seed(752979)
BATCH_SIZE = 170
features_train, features_test, y_train, y_test = train_test_split(train_pad, df_train['scc
                                                                  test_size=0.2, random_sta
train dataset = ReviewsDataset(features train, y train)
test_dataset = ReviewsDataset(features_test, y_test)
train_dataloader = torch.utils.data.DataLoader(train_dataset, batch_size=BATCH_SIZE)
test_dataloader = torch.utils.data.DataLoader(test_dataset, batch_size=BATCH_SIZE, shuffle
class LSTMRegressor(nn.Module):
    def init (self, hidden dim, label size, num emb = len(WORDS), embedding dim=600, bi
        super(LSTMRegressor, self). init ()
        self.emb = nn.Embedding(num emb, embedding dim)
        self.lstm = nn.LSTM(embedding dim, hidden dim,
                            bidirectional = bidirectional,batch_first=True)
        if bidirectional:
            self.layers = nn.Sequential(
            nn.Linear(hidden_dim*2, 200),
            nn.Dropout(p=0.2),
                nn.LeakyReLU(),
            nn.Linear(200, label size)
            self.fc = nn.Linear(hidden dim, label size)
        self.act1 = nn.ReLU()
```

```
def forward(self, x):
        embeds = self.emb(x)
        packed_outputs, (hidden,cell) = self.lstm(embeds)
        hidden = torch.cat((hidden[-2,:,:], hidden[-1,:,:]), dim = 1)
        output = self.layers(hidden)
        return output.squeeze()
def train_epoch(
    model,
    data_loader,
    optimizer,
    criterion,
    return_losses=False,
    device="cuda:0",
):
    model = model.to(device).train()
    total loss = 0
    num_batches = 0
    all losses = []
    total_predictions = np.array([])#.reshape((0, ))
    total_labels = np.array([])#.reshape((0, ))
    for item in data_loader:
        images = item[0]
        labels = item[1]
        # Move Batch to GPU
        images = images.to(device)
        labels = labels.to(device)
        predicted = model(images.long())
        predicted[predicted > 10] = 10
        predicted[predicted < 0] = 0</pre>
        loss = criterion(predicted.float(), labels)
        # Update weights
        loss.backward()
        optimizer.step()
        optimizer.zero_grad()
        # Update descirption for tqdm
        total loss += loss.item()
        num batches += 1
        all_losses.append(loss.detach().item())
    metrics = {"loss": total_loss / num_batches}
    return model
def validate(model, data_loader, criterion, device="cuda:0"):
    model = model.eval()
    total_loss = 0
    num batches = 0
    predicts = np.array([])
    total_predictions = np.array([])
    total labels = np.array([])
```

```
for images, labels in data loader:
        images = images.to(device)
        labels = labels.to(device)
        predicted = model(images.long())
        predicted[predicted > 10] = 10
        predicted[predicted < 0] = 0</pre>
        loss = criterion(predicted.float(), labels)
        predicts = np.append(predicts, predicted.cpu().detach().numpy())
        total loss += loss.item()
        num_batches += 1
   metrics = {"loss": total_loss / num_batches, 'answers': predicts}
    return metrics
model = LSTMRegressor(hidden_dim=120, label_size=1)
optimizer = torch.optim.Adam(model.parameters(), lr = 0.0001)
scheduler = torch.optim.lr_scheduler.MultiplicativeLR(optimizer, lr_lambda = lambda epoch:
loss function = nn.L1Loss()
NUM EPOCHS = 14
def train epochs(model,
    data_loader_train,
    data_loader_test,
    optimizer,
    criterion, scheduler,
    return losses=False,
   device="cuda:0", epochs = NUM_EPOCHS):
    for jj in tqdm(range(NUM_EPOCHS)):
        model = train_epoch(model, data_loader_train, optimizer, criterion, return_losses=
        metrics = validate(model, data_loader_test, criterion)
        print('On epoch {} MAE = {:.4f}'.format(jj + 1,metrics['loss']))
        scheduler.step()
    return model
model = train epochs(model, train dataloader, test dataloader, optimizer, loss function, s
print()
       7%
                     | 1/14 [01:00<13:02, 60.20s/it]On epoch 1 MAE = 1.1547
      14%|
                     | 2/14 [01:51<11:02, 55.18s/it]On epoch 2 MAE = 1.0570
      21%
                     3/14 [02:43<09:49, 53.55s/it]On epoch 3 MAE = 0.9999
                     | 4/14 [03:35<08:47, 52.75s/it]On epoch 4 MAE = 0.9446
      29%
                    | 5/14 [04:26<07:50, 52.27s/it]On epoch 5 MAE = 0.8947
      36%
      43%
                     6/14 [05:17<06:55, 51.99s/it]On epoch 6 MAE = 0.8721
                    7/14 [06:09<06:02, 51.78s/it] on epoch 7 MAE = 0.8648
      50%
                     | 8/14 [07:00<05:09, 51.66s/it]On epoch 8 MAE = 0.8584
      57%
                     9/14 [07:52<04:17, 51.59s/it]On epoch 9 MAE = 0.8576
      64%
                     | 10/14 [08:43<03:26, 51.54s/it]On epoch 10 MAE = 0.8577
      71%
      79%
                     | 11/14 [09:34<02:34, 51.52s/it]On epoch 11 MAE = 0.8584
                    | 12/14 [10:26<01:42, 51.49s/it]On epoch 12 MAE = 0.8560
      86%
                    | 13/14 [11:17<00:51, 51.41s/it]On epoch 13 MAE = 0.8638
      93%
     100%
                    | 14/14 [12:08<00:00, 52.07s/it]On epoch 14 MAE = 0.8504
```

Итого, нейронная сеть дала нам лучшее качество - 0.85!

▼ Контест (до 3 баллов)

По итогам всех ваших экспериментов выберите модель, которую считаете лучшей. Сделайте сабмит в контест. В зависимости от вашего скора на публичном лидерборде, мы начислим вам баллы:

- <0.77 3 балла
- [0.77; 0.78) 2 балла
- [0.78; 0.8) 1 балл

Тут я решил взять Градиентный бустинг на ворд2веке применить все это друг на друга. Удалось выбить 0.79 на внутреннем разбиении

```
def make_arrays_for_text_pos_idf(value):
   out_array = np.zeros(emb_size)
    for el in value:
        try:
            out array += best w 2 v pos.wv[el] * pos dict idf[el]
        except:
            continue
    return out array
# усредняем. Идею именно этой ячейки подсказал друг, но реализовал сам
def make_arrays_for_text_neg_idf(value):
   out_array = np.zeros(emb_size)
   for el in value:
        try:
            out array += best w 2 v neg.wv[el] * neg dict idf[el]
        except:
            continue
    return out array
df = df3.copy()
df2 = df.copy()
df2['positive vector'] = df2['positive'].apply(make arrays for text pos idf)
df2['negative_vector'] = df2['negative'].apply(make_arrays_for_text_neg_idf)
X features = pd.DataFrame(np.hstack((np.array(list(df2.iloc[:, 4].values)),
                                         np.array(list(df2.iloc[:, 5].values)))))
X features['score'] = df2['score']
X_features = X_features.fillna(0)
print(X_features.shape)
train2, test2 = train_test_split(X_features, test_size=0.2, random_state = 1412)
```

```
(50000, 1001)
```

Final score = 0.79

×